

Chapter 7

Curs 7

7.1 Legea slabă a numerelor mari

Reamintim că două variabile aleatoare X și Y se numesc necorelate dacă $M(X^2)$, $M(Y^2) < +\infty$ și are loc egalitatea

$$M(XY) = M(X)M(Y)$$

(în particular, această egalitate are loc dacă variabilele aleatoare sunt independente).

Definiția 7.1.1 *Spunem că o familie de variabile aleatoare $(X_i)_{i \in I}$ sunt necorelate dacă $M(|X_i|) < +\infty$, $i \in I$ și are loc*

$$M(X_i X_j) = M(X_i)M(X_j),$$

oricare ar fi $i, j \in I$ cu $i \neq j$.

Are loc următoarea:

Lema 7.1.2 *Dacă X_1, \dots, X_n sunt variabile aleatoare necorelate, atunci*

$$\sigma^2(X_1 + \dots + X_n) = \sigma^2(X_1) + \dots + \sigma^2(X_n)$$

(adică dispersia sumei unor variabile aleatoare necorelate este egală cu suma dispersiilor variabilelor aleatoare respective).

Demonstrație. Fie $\mu_i = M(X_i)$ și să notăm cu $S_n = X_1 + \dots + X_n$. Cum $M(S_n) = \sum_{i=1}^n M(X_i) = \sum_{i=1}^n \mu_i$, avem

$$\begin{aligned}\sigma^2(S_n) &= M\left((S_n - M(S_n))^2\right) = M\left(\left(\sum_{i=1}^n X_i - \mu_i\right)^2\right) \\ &= \sum_{i=1}^n M\left((X_i - \mu_i)^2\right) + 2 \sum_{1 \leq i < j \leq n} M\left((X_i - \mu_i)(X_j - \mu_j)\right) \\ &= \sum_{i=1}^n \sigma^2(X_i) + 2 \sum_{1 \leq i < j \leq n} M\left((X_i - \mu_i)(X_j - \mu_j)\right).\end{aligned}$$

Pentru a demonstra afirmația, arătăm că cea de-a doua sumă este egală cu zero. Pentru aceasta, observăm că

$$\begin{aligned}M\left((X_i - \mu_i)(X_j - \mu_j)\right) &= M(X_i X_j) - \mu_i M(X_j) - \mu_j M(X_i) + \mu_i \mu_j \\ &= M(X_i X_j) - \mu_i \mu_j \\ &= 0,\end{aligned}$$

deoarece variabilele aleatoare X_1, \dots, X_n sunt necorelate, încheiând demonstrația. ■

O primă variantă a legii numerelor mari este următoarea:

Teorema 7.1.3 *Fie X_1, X_2, \dots un șir de variabile aleatoare necorelate cu medii $M(X_i) = \mu$ și dispersii $\sigma^2(X_i) \leq C < +\infty$, $i \in I$. Atunci*

$$\frac{S_n}{n} = \frac{X_1 + \dots + X_n}{n} \xrightarrow{n \rightarrow \infty} \mu$$

în L^2 și în probabilitate.

Demonstrație. Să observăm că $M\left(\frac{S_n}{n}\right) = M\left(\frac{X_1 + \dots + X_n}{n}\right) = \mu$, și folosind lema anterioară obținem:

$$\begin{aligned}M\left(\left(\frac{S_n}{n} - \mu\right)^2\right) &= \sigma^2\left(\frac{S_n}{n}\right) \\ &= \frac{1}{n^2} \sigma^2(S_n) \\ &= \frac{1}{n^2} (\sigma^2(X_1) + \dots + \sigma^2(X_n)) \\ &\leq \frac{1}{n^2} Cn \\ &= \frac{C}{n} \rightarrow 0,\end{aligned}$$

adică $\frac{S_n}{n}$ converge la μ în L^2 .

Pentru a demonstra convergența în L^2 , din inegalitatea lui Cebâșev obținem

$$P\left(\left|\frac{S_n}{n} - \mu\right| \geq \varepsilon\right) \leq \frac{1}{\varepsilon^2} \sigma^2\left(\frac{S_n}{n}\right) \rightarrow 0,$$

pentru $n \rightarrow \infty$, oricare ar fi $\varepsilon > 0$, și deci $\frac{S_n}{n}$ converge la μ în probabilitate. ■

Un caz particular important al teoremei anterioare este cazul în care variabilele aleatoare X_1, X_2, \dots sunt independente (și deci sunt necorelate) și au aceeași distribuție. În acest caz, teorema anterioară afirmă că dacă $M(X_i^2) < +\infty$, atunci $S_n/n \rightarrow \mu = M(X_i)$ în L^2 și în probabilitate. Pentru a generaliza rezultatul de mai sus în cazul în care $M(|X_i|) < +\infty$, demonstrăm mai întâi următoarea:

Teorema 7.1.4 *Pentru fiecare $n \geq 1$, fie $X_{n,1}, X_{n,2}, \dots, X_{n,n}$ variabile aleatoare independente. Fie $(b_n)_{n \geq 1}$ un șir crescător de numere reale cu $b_n \nearrow +\infty$, și să notăm cu $\bar{X}_{n,k} = X_{n,k} 1_{\{|X_{n,k}| \leq b_n\}}$ și $a_n = \sum_{k=1}^n M(\bar{X}_{n,k})$. Dacă*

$$\text{i) } \sum_{k=1}^n P(|X_{n,k}| > b_n) \xrightarrow{n \rightarrow \infty} 0;$$

$$\text{ii) } \frac{1}{b_n^2} \sum_{k=1}^n M(\bar{X}_{n,k}^2) \xrightarrow{n \rightarrow \infty} 0,$$

atunci

$$\frac{S_n - a_n}{b_n} = \frac{X_{n,1} + \dots + X_{n,n} - a_n}{b_n} \xrightarrow[n \rightarrow \infty]{\mathcal{P}} 0.$$

Demonstrație. Să notăm $\bar{S}_n = \bar{X}_{n,1} + \dots + \bar{X}_{n,n}$. Pentru $\varepsilon > 0$ arbitrar fixat, avem:

$$\begin{aligned} P\left(\left|\frac{S_n - a_n}{b_n}\right| > \varepsilon\right) &\leq P\left(\left|\frac{S_n - a_n}{b_n}\right| > \varepsilon, S_n \neq \bar{S}_n\right) + P\left(\left|\frac{S_n - a_n}{b_n}\right| > \varepsilon, S_n = \bar{S}_n\right) \\ &\leq P(S_n \neq \bar{S}_n) + P\left(\left|\frac{\bar{S}_n - a_n}{b_n}\right| > \varepsilon\right) \\ &\leq P(\cup_{k=1}^n \{X_{n,k} \neq \bar{X}_{n,k}\}) + P(|\bar{S}_n - a_n| > \varepsilon b_n) \\ &\leq \sum_{k=1}^n P(X_{n,k} \neq \bar{X}_{n,k}) + \frac{M((\bar{S}_n - a_n)^2)}{(\varepsilon b_n)^2} \\ &= \sum_{k=1}^n P(|X_{n,k}| > b_n) + \frac{\sigma^2(\bar{S}_n)}{\varepsilon^2 b_n^2}. \end{aligned}$$

Cum variabilele aleatoare $X_{n,1}, \dots, X_{n,n}$ sunt independente, variabilele aleatoare $X_{n,1}, \dots, X_{n,n}$ sunt de asemenea independente, și deci avem:

$$\begin{aligned} \sigma^2(\bar{S}_n) &= \sigma^2(\bar{X}_{n,1} + \dots + \bar{X}_{n,n}) \\ &= \sigma^2(\bar{X}_{n,1}) + \dots + \sigma^2(\bar{X}_{n,n}) \\ &\leq M(\bar{X}_{n,1}^2) + \dots + M(\bar{X}_{n,n}^2). \end{aligned}$$

Obținem deci

$$P\left(\left|\frac{S_n - a_n}{b_n}\right| > \varepsilon\right) \leq \sum_{k=1}^n P(|X_{n,k}| > b_n) + \frac{1}{\varepsilon^2 b_n^2} \sum_{k=1}^n M(\bar{X}_{n,k}^2),$$

de unde folosind ipoteza obținem

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{S_n - a_n}{b_n}\right| > \varepsilon\right) = 0,$$

adică

$$\frac{S_n - a_n}{b_n} \xrightarrow{\mathcal{P}} 0,$$

încheiând demonstrația. ■

Folosind teorema anterioară, obținem următoarea:

Teorema 7.1.5 *Fie X_1, X_2, \dots un șir de variabile aleatoare independente și identic distribuite astfel încât*

$$nP(|X_i| > n) \xrightarrow{n \rightarrow \infty} 0,$$

și să notăm $S_n = X_1 + \dots + X_n$ și $\mu_n = M(X_1 1_{\{|X_1| \leq n\}})$. Atunci

$$\frac{S_n}{n} - \mu_n \xrightarrow{\mathcal{P}} 0.$$

Demonstrație. Să aplicăm teorema anterioară pentru $X_{n,k} = X_k$ și $b_n = n$, $n, k \geq 1$.

Pentru aceasta, să arătăm că sunt verificate ipotezele *i)* și *ii)* ale teoremei anterioare. Avem:

$$\sum_{k=1}^n P(|X_{n,k}| > n) = \sum_{k=1}^n P(|X_k| > n) = nP(|X_1| > n) \xrightarrow{n \rightarrow \infty} 0$$

și

$$b_n^{-2} \sum_{k=1}^n M(\bar{X}_{n,k}^2) = n^{-2} \sum_{k=1}^n M(\bar{X}_{n,k}^2) = n^{-2} \cdot nM(\bar{X}_{n,1}^2) = n^{-1}.$$

Să arătăm în continuare că $n^{-1}M(\bar{X}_{n,1}^2) \xrightarrow{n \rightarrow \infty} 0$. Pentru aceasta, folosind Lema 7.1.6 de mai jos, avem:

$$M(\bar{X}_{n,1}) = \int_0^\infty 2xP(|\bar{X}_{n,1}| > x) dx \leq \int_0^n 2xP(|X_1| > x) dx,$$

deoarece

$$\begin{aligned} P(|\bar{X}_{n,1}| > x) &= P(|X_1| 1_{\{|X_1| \leq n\}} > x) \\ &= \begin{cases} 0, & x > n \\ P(|X_1| > x) - P(|X_1| > n), & x \leq n \end{cases} \\ &\leq \begin{cases} 0, & x > n \\ P(|X_1| > x), & x \leq n. \end{cases} \end{aligned}$$

Să considerăm funcția $f(x) = 2xP(|X_1| > x)$. Deoarece $0 \leq g(x) \leq 2x$ și $\lim_{x \rightarrow \infty} g(x) = 0$ (conform ipotezei), rezultă că $M = \sup_{x \geq 0} g(x) < +\infty$. Mai mult, oricare ar fi $0 \leq K \leq \infty$ fixat, $M_K = \sup_{x > K} g(x) \leq M < +\infty$.

Pentru orice $n \geq K$ obținem:

$$\begin{aligned} M(\bar{X}_{n,1}) &\leq \int_0^n 2xP(|X_1| > x) dx = \int_0^n f(x) dx \\ &= \int_0^K f(x) dx + \int_K^n f(x) dx \\ &\leq K \cdot M + (n - K) \cdot M_K, \end{aligned}$$

de unde, trecând la limită cu $n \rightarrow \infty$, obținem:

$$\lim_{n \rightarrow \infty} \frac{1}{n} M(\bar{X}_{n,1}) \leq \lim_{n \rightarrow \infty} \frac{KM + (n - K)M_K}{n} = M_K,$$

oricare ar fi $K \geq 0$, și deci trecând la limită cu $K \rightarrow \infty$, obținem

$$\lim_{n \rightarrow \infty} \frac{1}{n} M(\bar{X}_{n,1}) \leq \lim_{K \rightarrow \infty} M_K = 0,$$

și deci $\lim_{n \rightarrow \infty} \frac{1}{n} M(\bar{X}_{n,1}) = 0$.

Sunt deci verificate ipotezele teoremei anterioare, și deci rezultă că

$$\frac{S_n - a_n}{b_n} = \frac{S_n - a_n}{n} \xrightarrow{\mathcal{P}} 0,$$

unde $a_n = \sum_{k=1}^n M(\bar{X}_{n,k}) = nM(\bar{X}_{n,1}) = nM(X_1 1_{\{|X_1| \leq n\}}) = n\mu_n$, adică

$$\frac{S_n}{n} - \mu_n \xrightarrow{\mathcal{P}} 0,$$

încheiând demonstrația. ■

În demonstrația teoremei anterioare, am utilizat următorul rezultat, util în calculul momentului unei variabile aleatoare:

Lema 7.1.6 *Dacă $X \geq 0$ este o variabilă aleatoare ne-negativă și $p > 0$, atunci are loc egalitatea*

$$M(X^p) = \int_0^\infty px^{p-1}P(X > x) dx.$$

Demonstrație. Din teorema Fubini (pentru variabile aleatoare ne-negative), avem:

$$\begin{aligned}
\int_0^\infty px^{p-1}P(X > x) dx &= \int_0^\infty px^{p-1}M(1_{\{X>x\}}) dx \\
&= \int_0^\infty M(px^{p-1}1_{\{X>x\}}) dx \\
&= M \int_0^\infty px^{p-1}1_{\{X>x\}} dx \\
&= M \int_0^X px^{p-1} dx \\
&= M(x^p|_0^X) \\
&= M(X^p),
\end{aligned}$$

încheiând demonstrația. ■

Cu această pregătire, putem acum demonstra varianta generală a legii slabe a numerelor mari, după cum urmează:

Teorema 7.1.7 (Legea slabă a numerelor mari) *Fie X_1, X_2, \dots variabile aleatoare independente și identic distribuite cu medie $\mu = M(X_1) < +\infty$. Atunci*

$$\frac{X_1 + \dots + X_n}{n} \xrightarrow{\mathcal{P}} \mu.$$

Demonstrație. Din teorema convergenței dominate, avem

$$nP(|X_1| > n) \leq M(|X_1| 1_{\{|X_1|>n\}}) \xrightarrow{n \rightarrow \infty} 0,$$

și

$$\mu_n = M(X_1 1_{\{|X_1| \leq n\}}) \xrightarrow{n \rightarrow \infty} M(X_1) = \mu.$$

Sunt deci verificate ipotezele teoremei anterioare, și deci

$$\frac{S_n}{n} - \mu_n = \frac{X_1 + \dots + X_n}{n} - \mu_n \xrightarrow{\mathcal{P}} 0.$$

Cum $\mu_n \rightarrow \mu$, obținem echivalent

$$\frac{X_1 + \dots + X_n}{n} \xrightarrow{\mathcal{P}} \mu,$$

încheiând demonstrația. ■

EXERCITII

Exercițiul 7.1.1 Fie X_1, X_2, \dots variabile aleatoare necorelate cu medii $M(X_n) = \mu_n$, $n = 1, 2, \dots$ astfel încât $\frac{\sigma^2(X_n)}{n} \xrightarrow{n \rightarrow \infty} 0$. Să se arate că

$$\frac{S_n}{n} - \nu_n \rightarrow 0$$

în L^2 și în probabilitate, unde $S_n = X_1 + \dots + X_n$ și $\nu_n = \frac{1}{n}M(S_n)$.

Exercițiul 7.1.2 Să se arate că dacă X_1, X_2, \dots sunt variabile aleatoare cu medii $M(X_n) = 0$, $n = 1, 2, \dots$ și $M(X_n X_m) \leq f(n-m)$ pentru $n \geq m \geq 1$, unde $\lim_{k \rightarrow \infty} f(k) = 0$, atunci

$$\frac{X_1 + \dots + X_n}{n} \xrightarrow{P} 0.$$

Exercițiul 7.1.3 Fie $f : [0, 1] \rightarrow \mathbb{R}$ o funcție măsurabilă astfel încât $\int_0^1 |f(x)| dx < +\infty$. Fie U_1, U_2, \dots un șir de variabile aleatoare independente, uniform distribuite pe intervalul $[0, 1]$, și să notăm

$$I_n = \frac{f(U_1) + \dots + f(U_n)}{n}.$$

- i) Să se arate că $I_n \xrightarrow{P} I = \int_0^1 f(x) dx$;
- ii) Dacă în plus $\int_0^1 f^2(x) dx$, să se utilizeze inegalitatea lui Cebâșev pentru a estima $P(|I_n - I| > \varepsilon)$, $\varepsilon > 0$.

Exercițiul 7.1.4 Să se arate că dacă $X \geq 0$ este o variabilă aleatoare discretă ne-negativă ce ia numai valori numere întregi, atunci

$$M(X) = \sum_{n=0}^{\infty} P(X \geq n).$$

Să se gasească o expresie similară pentru calculul momentului de ordin doi $M(X^2)$.

Exercițiul 7.1.5 Să se arate că dacă $H(x) = \int_{-\infty}^x h(y) dy$, unde $h : \mathbb{R} \rightarrow [0, +\infty)$ este o funcție integrabilă, atunci pentru orice valoare aleatoare ne-negativă are loc

$$M(H(X)) = \int_{-\infty}^{+\infty} h(y) P(X \geq y) dy.$$

Să se particularizeze formula obținută pentru $H(x) = x^p$, $p > 0$, respectiv $H(x) = e^{\alpha x}$, $\alpha > 0$.