

1.11 Teoreme limită

Teoremele limită constituie rezultatele teoretice cele mai importante ale teoriei probabilităților. Dintre acestea, cele mai importante sunt:

- legile numerelor mari (dau condiții în care media aritmetică a unui șir de variabile aleatoare converge într-un anumit sens la o anumită constantă - valoarea medie a mediei aritmetice respective);
- teoreme limită centrale (dau condiții în care suma unui număr de variabile aleatoare, corespunzător normată, converge la o variabilă aleatoare normală).

Vom demonstra mai întâi două inegalități:

Propoziția 1.11.1 (Inegalitatea lui Markov) *Dacă X este o variabilă aleatoare ce ia numai valori ne-negative (adică $X \geq 0$), atunci pentru orice $a > 0$ avem:*

$$P(X \geq a) \leq \frac{M(X)}{a}.$$

Demonstrație. Vom face demonstrația în cazul unei variabile aleatoare X continue, având densitatea $f(x)$.

Dacă $M(X) = +\infty$, inegalitatea este evident adevărată, și deci putem presupune că media $M(X)$ este finită. Avem

$$\begin{aligned} M(X) &= \int_{-\infty}^{+\infty} x f(x) dx \stackrel{X \geq 0}{=} \int_0^{+\infty} x f(x) dx \\ &\stackrel{a \geq 0}{\geq} \int_a^{+\infty} x f(x) dx \geq \int_a^{+\infty} a f(x) dx \\ &= a P(X \geq a), \end{aligned}$$

de unde rezultă (deoarece $a > 0$)

$$P(X \geq a) \leq \frac{M(X)}{a}.$$

■

Propoziția 1.11.2 (Inegalitatea lui Cebășev) *Dacă X este o variabilă aleatoare cu medie $M(X) = \mu$ și dispersie $D^2(X) = \sigma^2$ finite, atunci pentru orice $a > 0$ avem:*

$$P(|X - \mu| \geq a) \leq \frac{\sigma^2}{a^2}.$$

Demonstrație. Considerăm variabila aleatoare ne-negativă $Y = (X - \mu)^2$. Din inegalitatea lui Markov, obținem:

$$\begin{aligned} P(|X - \mu| \geq a) &= P\left((X - \mu)^2 \geq a^2\right) = P(Y \geq a^2) \\ &\leq \frac{M(Y)}{a^2} = \frac{M\left((X - \mu)^2\right)}{a^2} = \frac{D^2(X)}{a^2} \\ &= \frac{\sigma^2}{a^2}. \end{aligned}$$

■

Observația 1.11.3 Inegalitățile anterioare sunt importante deoarece ele dau margini superioare pentru anumite probabilități, atunci când numai media/dispersia sunt cunoscute, ca în exemplul următor:

Exemplul 1.11.4 Dacă X este o variabilă aleatoare cu medie $M(X) = 2$ și dispersie $D^2(X) = 9$, atunci din inegalitatea lui Cebâșev (pentru $a = 5$, spre exemplu) avem:

$$P(|X - 2| > 5) \leq \frac{D^2(X)}{5^2} = \frac{9}{25} = 0.36.$$

Dacă în plus $X \geq 0$, atunci din inegalitatea lui Markov (pentru $a = 7$, spre exemplu) avem:

$$P(X > 7) \leq \frac{M(X)}{7} = \frac{2}{7} \approx 0.285 \dots$$

Observația 1.11.5 Din inegalitatea lui Cebâșev rezultă că dacă dispersia unei variabile aleatoare X este $D^2(X) = 0$, atunci

$$P(|X - \mu| > a) = 0,$$

oricare ar fi $a > 0$, și deci

$$P(|X - \mu| > 0) = P\left(\bigcap_{n \geq 1} |X - \mu| > \frac{1}{n}\right) = \lim_{n \rightarrow \infty} P\left(|X - \mu| > \frac{1}{n}\right) = 0,$$

adică

$$P(X = \mu) = 1,$$

ceea ce arată că singurele variabile aleatoare având dispersie 0 sunt cele constante.

Teorema 1.11.6 (Legea slabă a numerelor mari) Fie X_1, X_2, \dots un șir de variabile aleatoare independente și identic distribuite, având medie $M(X_i) = \mu$ – finită. Atunci oricare ar fi $\varepsilon > 0$ avem

$$P\left(\left|\frac{X_1 + \dots + X_n}{n} - \mu\right| > \varepsilon\right) \xrightarrow{n \rightarrow \infty} 0$$

(adică șirul $\frac{X_1 + \dots + X_n}{n}$ converge în probabilitate către μ).

Demonstrație. Vom face demonstrația în ipoteza suplimentară că există dispersia $D^2(X_i) = \sigma^2 < +\infty$.

Pentru un $n \geq 1$ arbitrar fixat, considerând variabila aleatoare

$$Y = \frac{X_1 + \dots + X_n}{n},$$

avem

$$M(Y) = M\left(\frac{X_1 + \dots + X_n}{n}\right) = \frac{1}{n}(M(X_1) + \dots + M(X_n)) = \frac{n\mu}{n} = \mu$$

și

$$\begin{aligned} D^2(Y) &= D^2\left(\frac{X_1 + \dots + X_n}{n}\right) = \frac{1}{n^2} D^2(X_1 + \dots + X_n) \\ &\stackrel{X_1, X_2, \dots \text{ independente}}{=} \frac{1}{n^2} (D^2(X_1) + \dots + D^2(X_n)) \\ &= \frac{n\sigma^2}{n^2} \\ &= \frac{\sigma^2}{n}. \end{aligned}$$

Din inegalitatea Cebâșev avem

$$P\left(\left|\frac{X_1 + \dots + X_n}{n} - \mu\right| > \varepsilon\right) = P(|Y - \mu| > \varepsilon) \leq \frac{D^2(Y)}{\varepsilon^2} = \frac{\sigma^2/n}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

■

Teorema limită centrală este un rezultat fundamental, cu numeroase aplicații practice, ce afirmă că suma unui număr mare de variabile aleatoare independente este apoximativ o variabilă aleatoare normal distribuită, fapt ce explică de ce frecvențele relative ale multor populații statistice au o formă de clopot, adică sunt apoximativ normal distribuite.

Reamintim că o variabilă aleatoare normală $\mathcal{N}(\mu, \sigma^2)$ cu medie μ și dispersie σ^2 este o variabilă aleatoare continuă având densitatea

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

Teorema 1.11.7 (Teorema limită centrală) *Fie X_1, X_2, \dots un șir de variabile aleatoare idenpendente și identic distribuite, cu medie $M(X_i) = \mu$ și dispersie $D^2(X_i) = \sigma^2$ finite. Atunci distribuția variabilei aleatoare $\frac{X_1 + \dots + X_n - n\mu}{\sigma\sqrt{n}}$ tinde (pentru $n \rightarrow \infty$) la distribuția normală standard $\mathcal{N}(0, 1)$, adică:*

$$P\left(\frac{X_1 + \dots + X_n - n\mu}{\sigma\sqrt{n}} < a\right) \xrightarrow{n \rightarrow \infty} \int_{-\infty}^a \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = \Phi(x).$$

Pentru demonstrație vom folosi următoarea:

Lema 1.11.8 Fie Z_1, Z_2, \dots un șir de variabile aleatoare având funcțiile de distribuție F_{Z_n} și funcțiile generatoare de moment φ_{Z_n} , și fie Z o variabilă aleatoare cu funcția de distribuție F_Z și funcția generatoare de moment φ_Z . Atunci

$$\varphi_{Z_n} \xrightarrow{n \rightarrow \infty} \varphi_Z \implies F_{Z_n} \xrightarrow{n \rightarrow \infty} F_Z,$$

pentru orice valoare $t \in \mathbb{R}$ pentru care funcția de distribuție F_Z este continuă în acest punct.

Folosind faptul că funcția generatoare de moment a unei variabile aleatoare standard $Z \in \mathcal{N}(0, 1)$ este $\varphi_Z(t) = e^{t^2/2}$, în particular avem următoarea:

Lema 1.11.9 Fie Z_1, Z_2, \dots un șir de variabile aleatoare având funcțiile de distribuție F_{Z_n} și funcțiile generatoare de moment φ_{Z_n} . Dacă $\varphi_{Z_n} \xrightarrow{n \rightarrow \infty} e^{t^2/2}$, atunci

$$F_{Z_n} \xrightarrow{n \rightarrow \infty} \Phi_Z = \int_{-\infty}^a \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx,$$

oricare ar fi $t \in \mathbb{R}$.

Demonstrația teoremei limită centrale. Vom face demonstrația în ipoteza suplimentară că funcțiile generatoare de moment $\varphi_{X_n}(t) \stackrel{\text{not}}{=} \varphi_X(t)$ a variabilelor aleatoare X_n există și sunt finite oricare ar fi $t \in \mathbb{R}$.

Considerăm mai întâi cazul în care $\mu = 0$ și $\sigma^2 = 1$.

Avem în acest caz

$$\varphi_{\frac{X_i}{\sqrt{n}}}(t) = M\left(e^{t \frac{X_i}{\sqrt{n}}}\right) = \varphi_X\left(\frac{t}{\sqrt{n}}\right), \quad 1 \leq i \leq n,$$

și cum variabilele aleatoare X_1, \dots, X_n sunt independente, avem

$$\begin{aligned} \varphi_{\frac{X_1 + \dots + X_n}{\sqrt{n}}}(t) &= M\left(e^{t \frac{X_1 + \dots + X_n}{\sqrt{n}}}\right) = M\left(\prod_{i=1}^n e^{t \frac{X_i}{\sqrt{n}}}\right) \\ &= \prod_{i=1}^n M\left(e^{t \frac{X_i}{\sqrt{n}}}\right) = \prod_{i=1}^n \varphi_X\left(\frac{t}{\sqrt{n}}\right) \\ &= \left(\varphi_X\left(\frac{t}{\sqrt{n}}\right)\right)^n. \end{aligned}$$

Dezvoltând în serie Taylor funcția $\varphi_X(t)$ în jurul punctului $t = 0$, avem:

$$\varphi_X(t) = \varphi_X(0) + \frac{\varphi_X'(0)}{1!}t + \frac{\varphi_X''(0)}{2!}t^2 + R(t),$$

unde $\lim_{t \rightarrow \infty} \frac{R(t)}{t^2} = 0$.

Avem deci:

$$\begin{aligned}
\varphi_X(0) &= 1 + \frac{M(X)}{1!}t + \frac{M(X^2)}{2!}t^2 + R(t) = \\
&= 1 + \frac{\mu}{1!}t + \frac{\sigma^2 + \mu^2}{2!}t^2 + R(t) \\
&= 1 + \frac{0}{1!}t + \frac{1 + 0^2}{2!}t^2 + R(t) \\
&= 1 + \frac{t^2}{2} + R(t),
\end{aligned}$$

și deci

$$\left(\varphi_X\left(\frac{t}{\sqrt{n}}\right)\right)^n = \left(1 + \frac{t^2}{2n} + R\left(\frac{t}{\sqrt{n}}\right)\right)^n,$$

de unde obținem

$$\begin{aligned}
\lim_{n \rightarrow \infty} \varphi_{\frac{X_1 + \dots + X_n}{\sqrt{n}}}(t) &= \lim_{n \rightarrow \infty} \left(\varphi_X\left(\frac{t}{\sqrt{n}}\right)\right)^n \\
&= \lim_{n \rightarrow \infty} \left(1 + \frac{t^2}{2n} + R\left(\frac{t}{\sqrt{n}}\right)\right)^n \\
&= e^{\lim_{n \rightarrow \infty} n\left(\frac{t^2}{2n} + R\left(\frac{t}{\sqrt{n}}\right)\right)} \\
&= e^{\frac{t^2}{2} + \lim_{n \rightarrow \infty} t^2 \frac{R\left(\frac{t}{\sqrt{n}}\right)}{\left(\frac{t}{\sqrt{n}}\right)^2}} \\
&= e^{\frac{t^2}{2}}.
\end{aligned}$$

Conform lemei anterioare rezultă că

$$F_{\frac{X_1 + \dots + X_n}{\sqrt{n}}}(t) \rightarrow \Phi_Z = \int_{-\infty}^a \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx,$$

oricare ar fi $t \in \mathbb{R}$, încheiând demonstrația în cazul particular $\mu = 0$ și $\sigma^2 = 1$.

Pentru cazul general, considerăm variabilele aleatoare $\tilde{X}_i = \frac{X_i - \mu}{\sigma}$, $i \geq 1$, și cum variabilele aleatoare X_1, X_2, \dots sunt independente și identic distribuite, cu medie $M(X_i) = \mu$ și dispersie $D^2(X_i) = \sigma^2$, rezultă că variabilele aleatoare $\tilde{X}_1, \tilde{X}_2, \dots$ sunt de asemenea independente și identic distribuite, cu medie $M(\tilde{X}_i) = 0$ și dispersie $D^2(\tilde{X}_i) = 1$.

Coform cazului anterior demonstrat rezultă că

$$F_{\frac{\tilde{X}_1 + \dots + \tilde{X}_n}{\sqrt{n}}}(t) \rightarrow \Phi_Z = \int_{-\infty}^a \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx, \quad t \in \mathbb{R},$$

sau echivalent

$$F_{\frac{X_1 + \dots + X_n - n\mu}{\sigma\sqrt{n}}}(t) \rightarrow \Phi_Z = \int_{-\infty}^a \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx, \quad t \in \mathbb{R},$$

încheiând demonstrația. ■

Observația 1.11.10 *Există o variantă mai generală a legii numerelor mari (legea tare a numerelor mari). Ea afirmă următoarea:*

Teorema 1.11.11 (Legea tare a numerelor mari) *Dacă X_1, X_2, \dots sunt variabile aleatoare independente și identic distribuite, cu medie $M(X_i) = \mu$ finită, atunci*

$$P\left(\lim_{n \rightarrow \infty} \frac{X_1 + \dots + X_n}{n} = \mu\right) = 1.$$

În particular, considerăm un eveniment E ce poate apare în urma efectuării unui experiment cu probabilitate $P(E) = p$, și considerăm n repetiții ale acestui experiment. Definind șirul de variabile aleatoare

$$X_i = \begin{cases} 1, & \text{dacă ev. } E \text{ a apărut în experimentul } i \\ 0, & \text{în caz contrar} \end{cases}, \quad i \geq 1,$$

din legea tare a numerelor mari obținem:

$$\begin{aligned} 1 &= P\left(\lim_{n \rightarrow \infty} \frac{X_1 + \dots + X_n}{n} = M(X_1)\right) \\ &= P\left(\lim_{n \rightarrow \infty} \frac{\# \text{ apariții a lui } E}{\# \text{ total de încercări}} = p\right) \\ &= P\left(\lim_{n \rightarrow \infty} \text{frecvența relativă a lui } E = p\right), \end{aligned}$$

adică frecvența relativă de apariție a evenimentului E tinde când $n \rightarrow \infty$ aproape sigur către probabilitatea p de apariție a evenimentului E .

1.11.1 Exerciții

1. O fabrică produce în medie 50 produse pe săptămână.
 - (a) Ce se poate spune despre probabilitatea $P(X > 75)$?
 - (b) Dacă dispersia numărului de piese produse este $\sigma^2 = 25$, ce se poate spune despre probabilitatea $P(40 < X < 60)$?

Indicație: se folosesc inegalitățile Markov și Cebășev.

2. Se consideră o variabilă aleatoare X uniform distribuită pe intervalul $(0, 10)$.
 - (a) Să se calculeze media μ a variabilei aleatoare X
 - (b) Să se calculeze direct probabilitatea $P(|X - \mu| > 4)$
 - (c) Să se estimeze probabilitatea $P(|X - \mu| > 4)$ folosind inegalitatea lui Cebășev.
3. Considerăm X_1, \dots, X_{20} variabile aleatoare independente Poisson cu parametrul $\lambda = 1$.

- (a) Să se utilizeze inegalitatea Markov pentru a estima probabilitatea $P\left(\sum_{i=1}^{20} X_i > 15\right)$.
- (b) Să se utilizeze Teorema limită centrală pentru a estima probabilitatea $P\left(\sum_{i=1}^{20} X_i > 15\right)$.
4. Din experiență, un profesor știe că nota obținută la examen de un student este o variabilă aleatoare cu media 75 (din 100 puncte posibile).
- (a) Ce se poate spune despre probabilitatea $P(X > 85)$?
- (b) Dacă dispersia notelor obținute este $\sigma^2 = 25$, ce se poate spune despre probabilitatea $P(65 < X < 85)$?
5. Considerăm o variabilă aleatoare X având media $\mu = 20$ și dispersia $\sigma^2 = 20$. Ce se poate spune despre probabilitatea $P(0 \leq X \leq 40)$?

6. Numărul de candidați X ce se înscriu la un concurs este o variabilă aleatoare Poisson cu parametrul $\lambda = 100$. S-a hotărât ca dacă se înscriu mai mult de 120 de candidați, să se organizeze două examene, altfel să se organizeze un singur examen. Care este probabilitatea să fie nevoie să se organizeze două examene?

Indicație: Pentru calculul probabilității $P(X > 120)$ se va folosi aproximarea variabilei aleatoare Poisson prin variabila aleatoare binomială cu parametrii n și p , astfel încât $np = \lambda = 100$ (spre exemplu $n = 200$ și $p = \frac{1}{2}$), și deci $X = X_1 + \dots + X_{200}$, unde X_1, \dots, X_{200} sunt variabile aleatoare Bernoulli cu parametrul $p = \frac{1}{2}$. Se folosește acum Teorema limită centrală pentru aproximarea probabilității cerute. Răspuns: 0.0228...

7. Se aruncă 10 zaruri. Să se estimeze probabilitatea ca suma punctelor obținute să fie între 30 și 40.

Indicație: se folosește Teorema limită centrală. Răspuns: 0.65...

8. Fie X_1, \dots, X_{10} variabile aleatoare independente și uniform distribuite pe intervalul $(0, 1)$. Să se aproximeze probabilitatea $P\left(\sum_{i=1}^{10} X_i > 6\right)$.

Indicație: se folosește Teorema limită centrală. Răspuns: 0.16...

9. Se aruncă de 100 de ori un zar. Să se estimeze probabilitatea $P\left(\prod_{i=1}^{100} X_i \leq a^{100}\right)$, unde $a > 0$ este un număr arbitrar fixat (caz particular $a = 2$).

Indicație: probabilitatea dată se poate scrie

$$P\left(\prod_{i=1}^{100} X_i \leq a^{100}\right) = P\left(\sum_{i=1}^{100} \ln X_i \leq 100 \ln a\right),$$

și se folosește Teorema limită centrală.