

Proiect

Grupele 241 și 242

Notă: Raportul poate fi scris în *Microsoft Word* sau \LaTeX (pentru ușurință recomand folosirea pachetului *markdown* din *R* - mai multe informații găsiți pe site la secțiunea *Link-uri utile*). Toate simulările, figurile și codurile folosite trebuie incluse în raport (acesta trebuie să conțină comentarii și concluzii, acolo unde sunt cerute). Se va folosi doar limbajul *R* (scripturile trebuie să fie comentate).

1 Problema 1

Considerăm următoarele distribuții: $\mathcal{B}(n, p)$, $\text{Pois}(\lambda)$, $\text{Exp}(\lambda)$, $\mathcal{N}(\mu, \sigma^2)$

1. Generați $N = 1000$ de realizări independente din fiecare repartiție și calculați media și varianța eșantionului.
2. Ilustrați grafic funcțiile de masă, respectiv funcțiile de densitate pentru fiecare din repartițiile din enunțul problemei. Considerați câte 5 seturi de parametri diferiți pentru fiecare repartiție și suprapuneți graficele pe aceeași figură pentru fiecare repartiție. Adăugați și legenda.
3. Pentru seturile de parametri de la punctul anterior trasați funcțiile de repartiție pentru fiecare repartiție (tot suprapuse) și adăugați legenda corespunzătoare.

Scopul următoarelor subpuncte este de a evalua acuratețea unor aproximări ale funcției de repartiție a binomialei $\mathcal{B}(n, p)$, notată în cele ce urmează cu $F_{n,p}(k) = \mathbb{P}(X \leq k)$. Vom compara următoarele aproximări:

a) *Aproximarea Poisson*

$$F_{n,p}(k) \approx F_{\lambda}(k) = \sum_{x=0}^k e^{-\lambda} \frac{\lambda^x}{x!}, \quad \lambda = np$$

b) *Aproximarea Normală* (rezultată din Teorema Limită Centrală)

$$F_{n,p}(k) \approx \Phi\left(\frac{k - np}{\sqrt{np(1-p)}}\right)$$

c) *Aproximarea Normală cu factor de corecție*

$$F_{n,p}(k) \approx \Phi\left(\frac{k + 0.5 - np}{\sqrt{np(1-p)}}\right)$$

d) *Aproximarea Camp-Paulson* (A se vedea (Lesch and Jeske 2009))

$$F_{n,p}(k) \approx \Phi\left(\frac{c - \mu}{\sigma}\right)$$

pentru $c = (1-b)r^{\frac{1}{3}}$, $\mu = 1-a$ și $\sigma^2 = a + br^{\frac{2}{3}}$ unde $a = \frac{1}{9(n-k)}$, $b = \frac{1}{9(k+1)}$ și respectiv $r = \frac{[(k+1)(1-p)]}{[p(n-k)]}$.

Se cere:

4. Pentru fiecare $n \in \{25, 50, 100\}$ și fiecare $p \in \{0.05, 0.1\}$ să se afișeze un tabel cu șase coloane (**k**, **Binomiala**, **Poisson**, **Normala**, **Normala Corecție**, **Camp-Paulson**) în care să apară aproximările de mai sus pentru funcția de repartiție și de masă a binomialiei, pentru $k \in \{1, 2, \dots, 10\}$.
5. Pentru a cuantifica acuratețea aproximărilor de mai sus vom folosi ca metrică, *eroarea maximală absolută* dintre două funcții de repartiții F și H (numită și distanța Kolmogorov) dată de formula

$$d_K(F(k), H(k)) = \max_k |F(k) - H(k)|.$$

Pentru fiecare $n \in \{25, 50, 100\}$ ilustrați pe același grafic erorile maxime absolute (folosind diferite culori și simboluri pentru puncte) dintre funcția de repartiție binomială și cele patru aproximări de mai sus considerând $0.01 \leq p \leq 0.5$. Ce observați ?

Următoarele subpuncte fac referire la aproximarea funcției de repartiție a binomialiei $\mathcal{B}(n, p)$ prin intermediul repartiției normale-asimetrice (skew-normal) (Chang et al. 2008). Spunem că o variabilă aleatoare X este repartizată normal-asimetric de parametri μ (locatie), σ (scală) și λ (coeficient de asimetrie) și notăm $X \sim SN(\mu, \sigma, \lambda)$ dacă are densitatea de repartiție

$$f(x) = \frac{2}{\sigma} \phi\left(\frac{x - \mu}{\sigma}\right) \Phi\left(\lambda \frac{x - \mu}{\sigma}\right),$$

unde ϕ și Φ reprezintă densitatea respectiv funcția de repartiție a normalei standard.

6. Pentru 5 seturi de parametri diferiți ilustrați grafic densitățile repartiției normale-asimetrice, suprapunând graficele pe aceeași figură. Adăugați și legenda.

e) *Aproximarea prin normala asimetrică* este dată de

$$F_{n,p}(k) \approx \Psi_\lambda\left(\frac{k + 0.5 - \mu}{\sigma}\right)$$

unde $\Psi_\lambda(x) = \int_{-\infty}^x 2\phi(t)\Phi(\lambda t) dt$ este funcția de repartiție a normalei-asimetrice standard ($SN(0, 1, \lambda)$). Parametrii (μ, σ, λ) se obțin din următoarele relații:

- având date (n, p) , $\lambda = \text{sign}(1 - 2p)\sqrt{\lambda^2}$ unde λ^2 este soluția ecuației

$$\frac{\left(1 - \frac{2}{\pi} \frac{\lambda^2}{1 + \lambda^2}\right)^3}{\frac{2}{\pi} \left(\frac{4}{\pi} - 1\right)^2 \left(\frac{\lambda^2}{1 + \lambda^2}\right)^3} = \frac{np(1 - p)}{(1 - 2p)^2}$$

- pentru λ determinat anterior,

$$\sigma^2 = \frac{np(1 - p)}{1 - \frac{2}{\pi} \frac{\lambda^2}{1 + \lambda^2}}$$

- pentru λ și σ determinate mai sus,

$$\mu = np - \sigma \sqrt{\frac{2}{\pi} \frac{\lambda^2}{1 + \lambda^2}}$$

7. Folosind funcția `uniroot()` din **R** pentru determinarea soluțiilor unei ecuații reale (`help(uniroot)`), creați o funcție care să primească parametri (n, p) ca valori de intrare și să întoarcă valorile parametrilor (μ, σ, λ) conform relațiilor de mai sus. Ilustrați grafic pentru $n = 25$ și $p \in \{0.05, 0.1\}$ repartiția binomială $\mathcal{B}(n, p)$ (ca o funcție cu bare) peste care suprapuneți densitatea normalei-asimetrice corespunzătoare (cu parametri determinați corespunzător).

8. Pentru fiecare $n \in \{25, 50, 100\}$ și fiecare $p \in \{0.05, 0.1\}$ să se afișeze un tabel cu trei coloane (**k**, **Binomiala**, **Normala Asimetrică**) în care să apară aproximarea de mai sus pentru funcția de repartiție și de masă a binomialei. Pentru calculul funcției de repartiție a normalei-asimetrice standard, $\Psi_\lambda(x)$, folosiți funcția `integrate()` din **R** (`help(integrate)`). Evaluați grafic acuratețea aproximării conform punctului 5.

2 Problema 2

Obiectivul acestui exercițiu este de a simula un vector aleator (X_1, X_2) repartizat uniform pe discul unitate $D(1)$ (discul de centru $(0, 0)$ și de rază 1). Densitatea acestuia este

$$f_{(X_1, X_2)}(x_1, x_2) = \frac{1}{\pi} \mathbf{1}_{D(1)}(x_1, x_2).$$

Pentru aceasta vom folosi două metode. O primă metodă este metoda de simulare prin acceptare și respingere. Această metodă este des utilizată pentru generarea unei v.a. repartizate uniform pe o mulțime oarecare E . Metoda constă în generarea unei v.a. X repartizată uniform pe o mulțime $F \supset E$ mai simplă decât E , apoi de a testa dacă X se află în E sau nu. În caz afirmativ, păstrăm X altfel generăm o nouă realizare a lui X pe F .

1. Justificați teoretic că putem simula un vector (cuplu) aleator repartizat uniform pe pătratul $[-1, 1]^2$ plecând de la două v.a. independente repartizate uniform pe segmentul $[-1, 1]$.
2. Prin metoda acceptării și respingerii simulați $N = 1000$ de puncte independente repartizate uniform pe discul unitate $D(1)$. Reprezentați grafic punctele (X_i, Y_i) din interiorul discului unitate cu albastru, și pe celelalte cu roșu.
3. Calculați media aritmetică a distanței care separă cele N puncte de origine. Comparați rezultatul cu media teoretică a variabilei corespunzătoare.

O a doua metodă de simulare a unui punct (X, Y) repartizat uniform pe $D(1)$ constă în folosirea schimbării de variabilă în coordonate polare: $X = R \cos(\Theta)$ și $Y = R \sin(\Theta)$.

4. Plecând de la densitatea cuplului (X, Y) , găsiți densitatea v.a. R și Θ .¹
5. Simulați $N = 1000$ de puncte prin această metodă și ilustrați grafic aceste puncte (incluzând conturul cercului).

3 Problema 3

a) Construiți funcția `fgam` care implementează proprietățile integralei *gamma* după cum urmează:

- $\Gamma(1) = 1$
- $\Gamma(n) = (n-1)!$ pentru orice n natural nenul.
- $\Gamma(1/2) = \sqrt{\pi}$
- $\Gamma(a) = (a-1)\Gamma(a-1)$ pentru orice $a > 1$

Pentru $a < 1$ folosiți funcția `integrate` din **R** și calculați valoarea integralei.

b) Construiți funcția `fbet` care implementează proprietățile integralei *beta* după cum urmează:

¹Indicație: Aici puteți folosi următorul rezultat bazat pe formula de schimbare de variabilă în cazul multidimensional: Fie $\mathbf{X} = (X_1, \dots, X_n)$ un vector aleator cu densitatea $f_{\mathbf{X}}$ și $g: \mathbb{R}^n \rightarrow \mathbb{R}^n$ o funcție diferențiabilă de clasă C^1 , injectivă și cu Jacobianul nenul. Atunci vectorul aleator $\mathbf{Y} = g(\mathbf{X})$ are densitatea $f_{\mathbf{Y}}(y) = f_{\mathbf{X}}(g^{-1}(y)) \left| \det J_{g^{-1}}(y) \right|$ dacă $y \in Im(g)$ și 0 altfel

- $\beta(a, b) = \beta(b, a)$
 - $\beta(a, b) = \frac{\pi}{\sin(a\pi)}$ dacă $a + b = 1$ ($a > 0$ și $b > 0$)
 - $\beta(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$ (apelați funcția 'fgam' construită anterior)
- c) Fie X și Y două variabile aleatoare independente repartizate $X \sim \text{Gamma}(a, b)$ și $Y \sim \text{Beta}(a, b)$. Construiți funcțiile `fprobgammanr`, `fprobbetanr` și respectiv `fprobnr` cu nr luând valori de la 1 la 9 care primesc ca parametri valorile lui a și b asociate repartițiilor Gamma și respectiv Beta și care calculează următoarele probabilități (folosind funcțiile `fgam`, `fbet` și `optimise`):
- 1) $\mathbb{P}(X < 3)$
 - 2) $\mathbb{P}(2 < X < 5)$
 - 3) $\mathbb{P}(3 < X < 4 \mid X > 2)$
 - 4) $\mathbb{P}(Y > 2)$
 - 5) $\mathbb{P}(4 < X < 6)$
 - 6) $\mathbb{P}(0 < X < 1 \mid X < 7)$
 - 7) $\mathbb{P}(X + Y < 5)$
 - 8) $\mathbb{P}(X - Y > 0.5)$
 - 9) $\mathbb{P}(X + Y > 3 \mid X - Y > 0.5)$

Ilustrați comportamentul celor 9 funcții construite prin apelul acestora folosind valori pentru a și b alese de voi (cel puțin 3).

Observație: Nu confundați funcțiile Γ și β (adică integralele cu același nume) cu repartițiile omonime! Pentru repartițiile Gamma și respectiv Beta folosiți următoarele densități:

- dacă $X \sim \text{Gamma}(a, b)$ atunci $f(x) = \frac{1}{b^a \Gamma(a)} x^{a-1} e^{-\frac{x}{b}}$, $x > 0$, $a > 0$, $b > 0$
- dacă $Y \sim \text{Beta}(a, b)$ atunci $f(x) = \frac{1}{\beta(a, b)} x^{a-1} (1-x)^{b-1}$, $x \in (0, 1)$, $a > 0$, $b > 0$

- d) Calculați aceleași probabilități ca la punctul c) folosind funcțiile de sistem din R (nu cele construite de voi!) pentru repartițiile Gamma și respectiv Beta și construiți un tabel în care să centralizați rezultatele obținute (pe prima coloană rezultatele de la punctul c) iar pe a doua rezultatele de la punctul d)). Ce justificare găsiți pentru diferențele observate?

Referințe

Chang, Ching-Hui, Jyh-Jiuan Lin, Nabendu Pal, and Miao-Chen Chiang. 2008. "A Note on Improved Approximation of the Binomial Distribution by the Skew-Normal Distribution." *The American Statistician* 62 (2): 167–70. <https://doi.org/10.1198/000313008x305359>.

Lesch, Scott M., and Daniel R. Jeske. 2009. "Some Suggestions for Teaching About Normal Approximations to Poisson and Binomial Distribution Functions." *The American Statistician* 63 (3): 274–77. <https://doi.org/10.1198/tast.2009.08147>.